

Índice

1	Notación	1
2	Modelos ocultos de Markov	1
2.1	Modelado del tiempo	1
2.2	Razonamiento probabilístico en el tiempo	1
2.3	Distribución conjunta	1
2.4	Tipos de inferencia	1
2.5	Ejemplo: cálculo directo	2

1. Notación

Este documento usa la convención de [1] para distinguir distribuciones de probabilidades puntuales:

- $P(a)$ es un *número*: la probabilidad de que la variable tome el valor a .
- $\mathbf{P}(A)$ es un *vector* de números: la distribución de probabilidad sobre todos los valores del dominio de A . Así, $\mathbf{P}(A | B)$ denota la tabla completa de probabilidades condicionales.

Para secuencias temporales se escribe

$$X_{m:n} = X_m, X_{m+1}, \dots, X_n, \quad m, n \in \{0, 1, 2, \dots\}, \quad m \leq n. \quad (1.0.1)$$

Símbolos recurrentes:

Símbolo	Significado
T_m	tiempo de muestreo
$t_k = kT_m$	instante discreto k -ésimo
X_k	estado (no observable) en t_k
E_k	evidencia (observable) en t_k
e_k	valor concreto observado de E_k
α	constante de normalización
v, f	valores verdadero y falso

2. Modelos ocultos de Markov

2.1. Modelado del tiempo

Asumamos que vemos el mundo de forma discreta: tomamos “fotos” de la realidad cada cierto tiempo T_m , conocido como *tiempo de muestreo*, y observamos lo que hay en esas fotos. Algunas cosas se pueden observar, mientras que otras permanecen ocultas.

Definición 2.1 (Estado y evidencia). Sea $t_k = kT_m$ con $k = 1, 2, \dots$. Denotamos por X_k el *estado* del sistema en el tiempo t_k , el cual es un conjunto de variables **no observables**, y por E_k la *evidencia* en t_k , la cual es un conjunto de variables que **sí** podemos observar.

La notación de secuencias es la de (1.0.1): $X_{m:n} = X_m, \dots, X_n$ con $m \leq n$. El índice 0 se reserva para el estado inicial, anterior a cualquier observación.

2.2. Razonamiento probabilístico en el tiempo

Cuando incorporamos el tiempo a nuestros modelos, el objeto de interés es la distribución de probabilidad de X_k dados los estados anteriores $X_{0:k-1}$, es decir

$$\mathbf{P}(X_k | X_{0:k-1}), \quad (2.2.1)$$

llamada *modelo de transición*.

Escribir $X_{0:k-1}$ dice que el estado actual depende de *todos* los anteriores: el número de padres del nodo X_k crece sin límite con k , y con él el tamaño de la tabla de probabilidad condicional. Un supuesto que evita esto es pedir que X_k dependa sólo de un número finito de estados anteriores.

Supuesto 2.2 (Markov de primer orden). El estado actual depende únicamente del estado inmediatamente anterior:

$$\mathbf{P}(X_k | X_{0:k-1}) = \mathbf{P}(X_k | X_{k-1}). \quad (2.2.2)$$

Supuesto 2.3 (Proceso estacionario). La *forma* de la distribución de probabilidad no cambia con t_k : la tabla $\mathbf{P}(X_k | X_{k-1})$ es la misma para todo k .

Observación. Los dos supuestos son independientes entre sí. El de Markov limita *de cuántas* variables depende el estado; el de estacionariedad dice que los números de esa dependencia no se reindexan con el tiempo. Juntos hacen que el modelo completo se especifique con una sola tabla finita, sin importar cuántos pasos de tiempo se observen.

La evidencia E_k se relaciona con el estado mediante el *modelo del sensor*, para el cual se hace un supuesto análogo.

Supuesto 2.4 (Markov del sensor). La evidencia en t_k depende sólo del estado en t_k :

$$\mathbf{P}(E_k | X_{0:k}, E_{1:k-1}) = \mathbf{P}(E_k | X_k). \quad (2.2.3)$$

A $\mathbf{P}(E_k | X_k)$ se le llama *modelo del sensor* (o *modelo de observación*). Nótese que el índice de la evidencia empieza en 1: se asume que **no hay evidencia para el tiempo t_0** .

2.3. Distribución conjunta

La distribución de probabilidad del estado inicial se denota $\mathbf{P}(X_0)$. Con ella y con los tres supuestos anteriores, la distribución conjunta de los estados $X_{0:k}$ y las evidencias $E_{1:k}$ queda completamente determinada:

$$\mathbf{P}(X_{0:k}, E_{1:k}) = \mathbf{P}(X_0) \prod_{i=1}^k \mathbf{P}(X_i | X_{i-1}) \mathbf{P}(E_i | X_i). \quad (2.3.1)$$

Observación. El modelo entero se especifica entonces con tres piezas: la distribución inicial $\mathbf{P}(X_0)$, el modelo de transición $\mathbf{P}(X_i | X_{i-1})$ y el modelo del sensor $\mathbf{P}(E_i | X_i)$. Los dos productos dentro de la sumatoria de (2.3.1) son justamente los que se leen de la red bayesiana dinámica de la Figura 1.

2.4. Tipos de inferencia

Hay cuatro tipos de inferencias básicas sobre estos modelos:

- **Filtrado** (estimación de estado): obtener la distribución de probabilidad del estado *actual* dada toda la evidencia hasta ahora,

$$\mathbf{P}(X_k | E_{1:k} = e_{1:k}). \quad (2.4.1)$$

- **Predicción**: calcular la distribución de probabilidad de un estado *futuro* dada la evidencia disponible,

$$\mathbf{P}(X_{k+j} | E_{1:k} = e_{1:k}), \quad j > 0. \quad (2.4.2)$$




Figura 1: Estructura de la red bayesiana y de las distribuciones de probabilidad condicional del ejemplo de la sombrilla. El modelo de transición es $\mathbf{P}(Lluvia_k | Lluvia_{k-1})$ y el modelo del sensor es $\mathbf{P}(Sombrilla_k | Lluvia_k)$. Adaptada de [1].

- **Suavizado:** calcular la distribución de probabilidad de un estado *pasado* X_j ,

$$\mathbf{P}(X_j | E_{1:k} = e_{1:k}), \quad 0 \leq j \leq k. \quad (2.4.3)$$

- **Explicación más probable:** obtener la secuencia de estados más probable que haya generado las observaciones,

$$\arg \max_{X_{1:k}} P(X_{1:k} | E_{1:k} = e_{1:k}). \quad (2.4.4)$$

Observación. Filtrado, predicción y suavizado se distinguen sólo por la posición del estado consultado respecto al final de la evidencia: igual, posterior o anterior. La explicación más probable es de naturaleza distinta: no devuelve una distribución sino una secuencia completa, y en general *no* coincide con encadenar los estados individualmente más probables obtenidos por suavizado.

2.5. Ejemplo: cálculo directo

Ejemplo 2.5 (Filtrado por enumeración en el modelo de la sombrilla). Digamos que queremos calcular $\mathbf{P}(R_2 | M_{1:2} = [v, v])$, donde R_k abrevia $Lluvia_k$ y M_k abrevia $Sombrilla_k$, usando directamente la conjunta (2.3.1).

Marginalizando sobre las variables ocultas R_0 y R_1 y fijando la evidencia observada:

$$\begin{aligned} \mathbf{P}(R_2 | M_{1:2} = [v, v]) = \\ \alpha \sum_{R_1} \sum_{R_0} P(M_2 = v | R_2) P(R_2 | R_1) \\ \cdot P(M_1 = v | R_1) P(R_1 | R_0) P(R_0), \end{aligned} \quad (2.5.1)$$

donde α es una constante de normalización, elegida de modo que las entradas de la distribución resultante sumen 1.

Observación. Este cálculo por enumeración es correcto pero no escala: el número de términos de la suma crece exponencialmente con k , pues se marginaliza sobre $R_0, \dots, R_{k-1}$. El algoritmo de filtrado recursivo (*forward*) reutiliza el resultado del paso anterior y hace el trabajo constante por paso de tiempo.

Referencias

- [1] S. Russell y P. Norvig, *Artificial Intelligence: A Modern Approach*, 4ª ed., Pearson, 2021.